

Apple Vision Pro 手話認識MLガイド

初心者向け解説 + CNN/LSTM提出用レポート

評価対象	6名・339ウィンドウ
評価方法	6-fold LOSO
CNN Accuracy	77.2 ± 2.4%
LSTM Accuracy	80.9 ± 2.7%

Aoi Yamamoto
Summer Camp ML Development
2026年9月2日

目次

目次	2
第1部 ML初心者向けガイド	3
1. 今回の課題を一文で言うと	3
2. CSVの1行と、学習データ1件は違う	3
3. 生データから結果までの全体像	4
4. 前処理で行ったことと、その理由	4
5. なぜランダム分割ではなくLOSOなのか	5
6. Train、Validation、Testの役割	6
7. CNNとは何か、なぜ選んだのか	6
8. LSTMとは何か、なぜ選んだのか	6
9. 学習中に行った工夫	7
10. 評価指標の読み方	7
11. 混同行列の読み方	8
12. 結果をどう解釈するか	9
13. なぜこのアプローチを選んだか - 要約	11
14. そのまま使える説明例	11
15. よく聞かれそうな質問と回答	12
16. 言ってよいこと・まだ言えないこと	12
17. 用語集	13
18. 自分で確認する3問	13
第2部 提出用MLレポート	14
日本語サマリー	14
1. Accuracy and per-class F1	14
2. Confusion matrices	15
3. Steps done	16
4. Limitations	16
Output files	17

第1部 ML初心者向けガイド


この資料の目的は、今回のCNN/LSTM実験について、次の3点を自分の言葉で説明できるようになることです。

1. 何を入力し、何を予測したのか
2. どのように公平な評価をしたのか
3. なぜCNNとLSTM、LOSO、F1スコアなどを選んだのか

1. 今回の課題を一文で言うと

Apple Vision Proで約3秒間記録した両手の動きから、Hello、ThankYou、Yes、No、Help、Rest の6クラスを判定する問題です。

これは「分類問題」です。分類問題とは、入力されたデータを、あらかじめ決められたカテゴリのどれかに割り当てる問題です。



2. CSVの1行と、学習データ1件は違う

CSVの1行は「ある瞬間の1フレーム」です。今回の記録は約30 fpsなので、3秒間で約90フレームになります。

モデルへ渡す学習データ1件は、1行ではなく、同じ window_id を持つ約90行を時系列順にまとめた「1ウィンドウ」です。

1フレーム = ある瞬間の手の位置
 約90フレーム = 1回の手話動作
 1ウィンドウ = 学習データ1件

今回使用したデータは次のとおりです。

項目	内容
被験者	S01、S02、S03、S04、S05、S07の6名
学習・評価対象	339ウィンドウ
クラス	6種類
1ウィンドウ	90フレーム
1フレームの特徴	164個

164特徴の内訳は、両手の関節座標162個と、左右の手が追跡できているかを表す2個のフラグです。

27関節 × 2手 × xyz 3軸 = 162座標
 左手・右手の追跡フラグ = 2
 合計 = 164特徴 / フレーム

したがって、モデルが受け取る1件のデータは、おおよそ「90行 × 164列の表」だと考えられます。

3. 生データから結果までの全体像



以降では、それぞれの処理が必要な理由を説明します。

4. 前処理で行ったことと、その理由

4.1 採用された本番データだけを使う

使用条件は次の2つです。

```
is_warmup == 0
kept == 1
```

- ウォームアップは練習なので評価対象にしません。
- `kept == 0` は収録時にやり直しと判断されたデータなので除外します。

低品質と分かっているデータまで学習すると、モデルが正しい手話ではなく、失敗した動作まで覚えてしまう可能性があります。

4.2 頭を基準にした座標へ変換する

Vision Proが記録する生の座標は、部屋の中の世界座標です。同じ手話でも、立つ位置や顔の向きが変わると数値が変わります。

そこで、手の座標から頭の位置を引き、頭の向きに合わせて回転させました。

```
変換前：「部屋のどこに手があるか」
変換後：「頭から見て、どこに手があるか」
```

手話では顔や身体に対する手の位置が重要です。そのため、部屋基準よりも頭基準の方が、被験者や立ち位置の違いを減らしやすいと考えました。

4.3 すべて90フレームにする

実際の記録は90フレームまたは91フレームなど、わずかに長さが違います。ニューラルネットワークへまとめて入力するには、同じ長さにする方が扱いやすいため、最初の90フレームへ統一しました。

- 90より長い場合：後ろを切る

- 90より短い場合：最後の値で埋める

これは実装が単純で比較しやすい方法ですが、動作速度の違いを完全には扱えません。この点はLimitationsです。

4.4 手を追跡できなかったフレームを扱う

S07では、採用フレームのうち左手28.1%、右手14.0%が未追跡でした。未追跡座標をそのまま0にすると、「本当に座標0に手があった」とモデルが誤解する可能性があります。

そこで、次の2段階で扱いました。

1. 前後に追跡できたフレームがあれば、途中の位置を時間方向に補間する
2. 左右の手が追跡できていたかを、別の2特徴としてモデルへ渡す

つまり、推定した座標だけでなく「この値は本当に観測できたか」もモデルへ伝えています。

4.5 訓練データだけで標準化する

座標ごとに値の大きさが違うため、平均0、標準偏差1に近づける標準化を行いました。

重要なのは、平均と標準偏差を訓練被験者だけから計算した点です。テスト被験者の統計量まで使うと、答えを見る前にテストデータの情報を利用したことになり、「データリーク」が起きます。

5. なぜランダム分割ではなくLOSOなのか

ランダム分割の問題


339ウィンドウを無作為に80%と20%へ分けると、同じ被験者の動作が訓練とテストの両方へ入ります。

モデルが「手話の一般的な特徴」ではなく、「その人特有の手の大きさや動かし方」を覚えた場合でも、高い精度が出る可能性があります。

LOSOの考え方

LOSOは Leave-One-Subject-Out の略で、1人を完全にテスト専用として残します。

今回の1つ目のfoldは、次のようになります。



テスト担当を交代して6回繰り返す

その後、テスト担当をS02、S03……と交代し、全員が1回ずつテストになるよう6回繰り返します。

Fold	Test	Validation	Train
1	S01	S02	S03, S04, S05, S07
2	S02	S03	S01, S04, S05, S07
3	S03	S04	S01, S02, S05, S07
4	S04	S05	S01, S02, S03, S07

Fold	Test	Validation	Train
5	S05	S07	S01, S02, S03, S04
6	S07	S01	S02, S03, S04, S05

この分割を選んだ理由は、最終的に実現したいことが「収録済みの同じ人を当てること」ではなく、「まだ学習に使っていない人の手話を認識すること」だからです。

6. Train、Validation、Testの役割

データ	役割	たとえ
Train	モデルのパラメータを学習する	教科書と練習問題
Validation	学習をいつ止めるか判断する	模擬試験
Test	最後に性能を測る	本番試験

Testを見ながらモデルを調整すると、本番試験の答えを見ながら勉強することになります。そのため、Testは最後の評価だけに使用しました。

7. CNNとは何か、なぜ選んだのか

CNNは Convolutional Neural Network の略です。画像に使われることが多いモデルですが、時間方向へ畳み込みを行う1D-CNNは時系列にも利用できます。

今回のCNNは、短い時間範囲を順番に見ながら、特徴的な動きのパターンを探します。

```

フレーム 1 2 3 4 5 6 7 ...
          └─ 短い範囲 ─┘
              ↓
        局所的な動きの特徴を検出
  
```

CNNを選んだ理由：

- 既存コードにCNNのベースラインがあり、約77%の結果と比較できる
- LSTMより並列計算しやすく、一般に学習が速い
- 短時間の手の形や動きのパターンを検出しやすい
- 時系列分類の基準モデルとして分かりやすい

8. LSTMとは何か、なぜ選んだのか

LSTMは Long Short-Term Memory の略で、時系列の順番を扱うためのニューラルネットワークです。

手話では「手がどこにあるか」だけでなく、「どの方向からどの方向へ動いたか」が重要です。LSTMは、前の時刻までの情報を内部状態として持ちながら次のフレームを読みます。

今回は双方向LSTM（BiLSTM）を使いました。

```

過去から未来へ → → →
フレーム      1 2 3 ... 90
未来から過去へ ← ← ←
  
```

BiLSTMを選んだ理由：

- 手話の時間的な順番と長めの動きを学習しやすい
- 収録済みの3秒全体を見て分類するオフライン課題に適している
- CNNとは異なる時系列の捉え方を比較できる
- チャット上でAoiさんの担当モデルとして指定されていた

注意点として、未来側のフレームも使うBiLSTMは、動作の途中で即座に答える完全リアルタイム用途にはそのまま使えません。今回は3秒の記録終了後に分類する評価なので採用しました。

9. 学習中に行った工夫

クラス重み付き損失

S07の件数が少ないため、各クラスは56件または57件でした。大きな偏りではありませんが、少数クラスを無視しにくくするため、訓練fold内の件数からクラス重みを計算しました。

Early Stopping

学習を続けすぎると、訓練データだけに適応する過学習が起きます。ValidationのMacro F1が改善しない状態が12 epoch続いたら学習を停止しました。

3つの乱数seed

ニューラルネットワークは、最初の重みやデータを読む順番に乱数を使います。同じ条件でも1回ごとに結果が少し変わるため、seed 0、1、2の3回を実行し、平均とばらつきを報告しました。

10. 評価指標の読み方

Accuracy

全予測のうち、正解した割合です。

$$\text{Accuracy} = \text{正解数} \div \text{全データ数}$$

直感的ですが、あるクラスだけ多いデータでは、多数派だけを当てても高くなる場合があります。

Precision

モデルがあるクラスだと予測したもののうち、本当にそのクラスだった割合です。

「Yesと予測したとき、どの程度信用できるか」

Recall

本当はそのクラスだったデータのうち、モデルが見つけられた割合です。

「本当のYesを、どの程度見逃さなかったか」

F1スコア

PrecisionとRecallの両方をまとめた指標です。0から1の範囲で、1に近いほど良い結果です。


Macro F1

6クラスそれぞれのF1を計算して、単純平均した値です。件数が少ないクラスも同じ1クラスとして評価するため、全クラスをバランスよく認識できているか確認できます。


11. 混同行列の読み方

- 行：本当のクラス
- 列：モデルが予測したクラス
- 左上から右下の対角線：正解
- 対角線以外：誤分類

CNN



LSTM



例えばLSTMの代表実行では、本当は Yes だった57件のうち、24件を正しく Yes と認識しました。一方、15件を No、10件を Rest と誤認しています。このことから、Yesの動きを区別するためのデータや特徴が不足している可能性が分かります。

12. 結果をどう解釈するか

全体結果

Model	Accuracy	Macro F1
CNN	77.2 ± 2.4%	76.6 ± 2.4%
LSTM	80.9 ± 2.7%	80.1 ± 2.7%

LSTMはCNNよりAccuracyが約3.7ポイント高くなりました。今回のデータでは、局所的なパターンを見るCNNより、時間の順番を扱うLSTMの方が少し適していたと解釈できます。

ただし、「LSTMが常にCNNより優れている」とは言えません。被験者は6名だけであり、データや設定が変われば結果も変わるためです。

クラス別結果

Class	CNN F1	LSTM F1
Hello	87.5 ± 2.8%	96.5 ± 0.7%
ThankYou	85.3 ± 4.5%	87.9 ± 6.2%
Yes	59.9 ± 3.2%	63.5 ± 6.0%
No	66.0 ± 2.2%	72.7 ± 2.0%
Help	85.2 ± 4.0%	93.1 ± 4.4%
Rest	75.7 ± 6.5%	67.0 ± 2.1%

- Hello と Help はLSTMで非常に高いF1でした。
- Yes、No、Rest は互いに混同されやすいクラスでした。
- Rest だけはCNNの方が高く、モデルごとに得意な動きが異なることが分かります。

S07を含めた意味

S07は他の被験者より未追跡フレームが多く、39ウィンドウしかありません。それでも除外せずLOSOへ入れることで、追跡状態が悪い新しい人に対してどの程度動くかを確認できました。

S07をテストにしたときの3回平均Accuracyは次のとおりです。

Model	S07 Accuracy
CNN	59.8%
LSTM	74.4%

これは、追跡マスクと時間的な情報を利用したLSTMが、今回のS07に対して比較的頑健だった可能性を示します。ただし、S07一人だけの結果なので一般化はできません。

13. なぜこのアプローチを選んだか - 要約

選択	選んだ理由
6クラス分類	プロジェクトのラベルが6種類だから
頭基準座標	部屋の位置や顔の向きの影響を減らすため
90フレーム	3秒記録を同じ形でモデルへ入力するため
補間 + 追跡マスク	未追跡を本物の座標0と誤解させないため
LOSO	初めて見る被験者への性能を測るため
別のValidation被験者	Testを見ずにEarly Stoppingするため
CNN	高速で分かりやすい時系列ベースラインだから
BiLSTM	手話の時間的な順番を捉えやすいから
クラス重み	クラス件数の小さな差を補うため
Macro F1	全クラスを同じ重みで評価するため
3 seed	1回だけの偶然による結果を避けるため

14. そのまま使える説明例

30秒版

Vision Proから取得した両手54関節の3次元座標を、頭を基準とする座標へ変換し、約3秒・90フレームの時系列としてCNNとLSTMへ入力しました。評価では、同じ人のデータが訓練とテストに入ると精度が過大評価されるため、1人ずつ完全にテストへ残すLOSOを使いました。6名339件を3つのseedで評価した結果、CNNはAccuracy 77.2%、LSTMは80.9%で、今回のデータでは時間的な順番を扱うLSTMが少し良い結果でした。

2分版

今回は、Vision Proで記録した約3秒間の手の動きから6種類の手話を分類しました。1フレームには左右54関節のxyz座標があり、これを頭基準へ変換して、立ち位置や顔の向きの影響を減らしました。各記録は90フレームへ統一しています。S07では手を追跡できないフレームが多かったため、前後の値から補間し、同時に追跡できていたかを示すマスクもモデルへ渡しました。

評価には被験者単位のLOSOを使いました。これは、1人を完全にテストへ残し、残りの人だけで学習する方法です。ランダム分割では同じ人が訓練とテストに入り、その人の癖を覚えてだけでも高精度になる可能性があるためです。また、別の1人をValidationとしてEarly Stoppingに使い、テストデータを見ながら調整しないようにしました。

モデルは、短い動きの特徴を見つける1D-CNNと、時間の順番を記憶する双方向LSTMを比較しました。3つの乱数seedでの平均AccuracyはCNNが77.2%、LSTMが80.9%でした。LSTMの方が全体では良好でしたが、Yes、No、Restの混同が残っており、被験者も6名だけなので、より多くのデータと実環境での検証が必要です。

15. よく聞かれそうな質問と回答

Q1. なぜ通常のランダムなTrain/Test分割を使わなかったのですか？

同じ被験者の動きがTrainとTestの両方へ入ると、モデルがその人の癖を覚えて高い精度を出す可能性があるからです。今回は初めて見る人への性能を測りたいため、被験者単位のLOSOを使用しました。

Q2. なぜ頭を基準にしましたか？

手話では身体や顔に対する手の位置が重要だからです。世界座標のままだと、部屋のどこに立ったかという不要な違いが入ります。

Q3. なぜCNNとLSTMを比較したのですか？

CNNは短い局所的な動きの特徴、LSTMは時間的な順番や長めの依存関係を扱うのが得意です。異なる考え方の時系列モデルを同じ条件で比較するためです。また、Aoiさんの担当モデルとして指定されていました。

Q4. なぜAccuracyだけでは不十分ですか？

Accuracyは全体の正解率しか示しません。クラス別F1と混同行列を見ることで、どの手話が認識でき、どの手話を混同しているかが分かります。

Q5. 80.9%なら実用化できますか？

まだ言えません。6名、6クラス、各1セッションのオフライン評価だからです。別の日、別の環境、より多くの被験者、リアルタイム動作で確認する必要があります。

Q6. S07は追跡欠損が多いのに、なぜ使ったのですか？

現実には常に完全な追跡が得られるとは限らず、新しい被験者への頑健性を確認できるからです。ただし、結果へ大きな影響を与えるため、欠損率をLimitationsとして明記しました。

Q7. なぜ3回実行したのですか？

ニューラルネットワークの結果は初期値や学習順の乱数で変わるからです。1回の最良値ではなく、平均とばらつきを示す方が誠実な報告になります。

Q8. LSTMが良かった理由は何ですか？

今回の手話では、瞬間的な手の形だけでなく、動く順番や軌跡が重要だった可能性があります。ただし、データ数が少ないため、理由が確定したとは言えません。

16. 言ってよいこと・まだ言えないこと

結果から言ってよいこと

- 今回の6名・339件では、LSTMの平均AccuracyがCNNより約3.7ポイント高かった。
- LOSOを使い、テスト被験者を訓練から分離した。
- Hello と Help は比較的認識しやすく、Yes、No、Rest は混同されやすかった。
- S07を含めても学習と評価を実行できた。

まだ言えないこと

- すべての人に80.9%で使える。
- 実際のリアルタイム環境でも同じ精度が出る。

- LSTMが常にCNNより優れている。
- 6種類以外の手話も認識できる。
- 追跡欠損の影響を完全に解決できた。

17. 用語集

用語	短い意味
Feature	モデルへ渡す数値。今回は関節座標や追跡フラグ
Label / Class	正解カテゴリ。今回は6種類の手話
Window	約3秒分をまとめた学習データ1件
Model	入力からクラスを予測する仕組み
Training	モデルの重みを学習すること
Validation	学習設定や停止時期を決めるためのデータ
Test	最終性能を測るための未使用データ
Epoch	訓練データ全体を1回学習する単位
Loss	予測が正解からどの程度ずれているかを示す値
Overfitting	訓練データだけを覚え、未知データに弱くなること
Data leakage	Testの情報が学習や調整に混入すること
LOSO	1人を完全にテストに残す被験者単位評価
Accuracy	全体の正解率
F1	PrecisionとRecallのバランス
Macro F1	クラス別F1を同じ重みで平均した値
Confusion matrix	正解クラスと予測クラスの組み合わせ表
Seed	乱数を再現するための番号

18. 自分で確認する3問

1. なぜ1フレームではなく約90フレームを1件として扱うのでしょうか？
2. 同じ被験者をTrainとTestへ入れると、なぜ評価が高く見える可能性があるのでしょうか？
3. Accuracyが高くて、混同行列とクラス別F1を見る必要があるのはなぜでしょうか？

答えを自分の言葉で説明できれば、今回の実験の中心部分を理解できています。

第2部 提出用MLレポート

日本語サマリー

Apple Vision Proで収集した手関節座標を用いて、1D-CNNと双方向LSTMを比較した。S07を含む6名、合計339ウィンドウを使用し、同一被験者が訓練とテストに混在しない6-fold Leave-One-Subject-Out (LOSO) で評価した。

3つの乱数seedの平均では、LSTMがAccuracy **80.9 ± 2.7%**、Macro F1 **80.1 ± 2.7%**となり、CNNのAccuracy **77.2 ± 2.4%**、Macro F1 **76.6 ± 2.4%**を上回った。S07単独のテストAccuracyも、LSTMは平均74.4%、CNNは平均59.8%だった。

1. Accuracy and per-class F1

Accuracy and Macro F1 are the mean ± population standard deviation over seeds 0, 1, and 2. Per-class F1 uses the same aggregation.

Model	Accuracy	Macro F1
1D-CNN	77.2 ± 2.4%	76.6 ± 2.4%
BiLSTM	80.9 ± 2.7%	80.1 ± 2.7%


Class	CNN F1	LSTM F1
Hello	87.5 ± 2.8%	96.5 ± 0.7%
ThankYou	85.3 ± 4.5%	87.9 ± 6.2%
Yes	59.9 ± 3.2%	63.5 ± 6.0%
No	66.0 ± 2.2%	72.7 ± 2.0%
Help	85.2 ± 4.0%	93.1 ± 4.4%
Rest	75.7 ± 6.5%	67.0 ± 2.1%

The representative run used for each confusion matrix is the seed whose overall Accuracy is closest to the three-seed mean:


Model	Representative seed	Accuracy	Macro F1
1D-CNN	1	75.8%	75.1%
BiLSTM	2	81.7%	80.5%

2. Confusion matrices

1D-CNN



BiLSTM



LSTM confusion matrix

The largest remaining errors are among Yes, No, and Rest. LSTM substantially improves Hello, ThankYou, and Help, but Yes and Rest remain difficult.

3. Steps done

1. Loaded every Data/*.csv file and retained only `is_warmup == 0` and `kept == 1` windows.
2. Used six subjects: S01, S02, S03, S04, S05, and S07.
3. Converted 54 hand joints from world coordinates to head-relative coordinates using the recorded head position and quaternion.
4. Sorted frames by `frame_index` and fixed each window at 90 frames by truncating or padding.
5. Interpolated temporary tracking gaps. Added left- and right-hand tracking flags as two explicit input channels, giving 164 features per frame.
6. Standardized coordinates using observed frames from the training subjects only. Validation and test data never contributed to normalization statistics.
7. Used six-fold LOSO. In each outer fold, one subject was held out for testing and a different subject was held out for validation and early stopping. The remaining four subjects were used for training.
8. Used class-weighted cross-entropy, AdamW, validation Macro F1 early stopping, and seeds 0, 1, and 2.
9. Evaluated a temporal 1D-CNN and a bidirectional LSTM under the same folds and preprocessing.
10. Saved fold metrics, seed metrics, per-class F1, confusion matrices, and an environment summary under `results/aoi_ml/`.

Reproduction

On Windows PowerShell from the repository root:

```
python -m venv .venv
.%.venv%Scripts%python.exe -m pip install -r requirements-ml.txt
.%.venv%Scripts%python.exe ml\aoi_lstm_cnn.py --output-dir results\aoi_ml --seeds 0 1 2 --max-epochs 80 --patience 12 --threads 4
```

S07 is intentionally not included in Git. To reproduce the exact reported numbers, its CSV must be provided privately and placed directly under Data/ before running the command.

4. Limitations

- Only six subjects were evaluated, with one recording session per subject. Generalization across days, devices, environments, and a larger population remains unknown.
- S01-S05 contain 60 kept test windows each, while S07 contains 39. The final class supports are therefore 56-57 rather than perfectly balanced.
- S07 has substantially more tracking loss than the existing data: 28.1% of kept frames have an untracked left hand and 14.0% have an untracked right hand. Interpolation and tracking-mask channels reduce, but do not eliminate, this domain shift.
- Each fold uses only one validation subject. Results can depend on which subject is selected for early stopping, especially with the small dataset.
- Windows are fixed to the first 90 frames. Truncation or end padding may discard timing information.
- Hyperparameters were deliberately limited; a full nested search was not performed.

- Yes, No, and Rest remain confused, suggesting that additional motion features, more subjects, or more consistent recordings may be needed.
- Offline classification was evaluated; latency and accuracy in live Vision Pro inference were not measured.

Output files

- `results/aoi_ml/fold_metrics.csv`: subject-level results for every seed and fold
- `results/aoi_ml/seed_metrics.csv`: overall LOSO results for each seed
- `results/aoi_ml/per_class_f1.csv`: per-class mean, standard deviation, and representative-run F1
- `results/aoi_ml/*_confusion_matrix.csv`: numeric confusion matrices
- `results/aoi_ml/*_confusion_matrix.png`: presentation-ready confusion matrices
- `results/aoi_ml/summary.json`: dataset, model, evaluation, and environment summary